

ĐỀ XUẤT KỸ THUẬT

Audio Processing & Temporal Alignment Pipeline

Người thực hiện: *Nguyễn Đăng Khoa*
AI Challenge 2026

Tháng 7 năm 2026

Tóm tắt nội dung

Đề xuất này trình bày thiết kế của mô-đun *Audio Processing & Temporal Alignment*, có nhiệm vụ chuyển đổi luồng âm thanh trong video thành văn bản kèm mốc thời gian và đồng bộ văn bản đó với các cảnh hình ảnh. Giải pháp sử dụng Faster-Whisper (large-v3) làm mô hình nhận dạng tiếng nói chính, kết hợp Voice Activity Detection (VAD), chuẩn hóa âm lượng, phân đoạn theo thời gian và bước làm sạch văn bản bằng mô hình ngôn ngữ nhẹ. Kết quả đầu ra là dữ liệu JSON thống nhất, sẵn sàng cho các tác vụ tìm kiếm, tóm tắt và phân tích video đa phương thức.

Mục lục

1	Bối cảnh và vấn đề	3
2	Mục tiêu và phạm vi	3
2.1	Mục tiêu	3
2.2	Phạm vi	3
3	Lựa chọn mô hình	3
4	Kiến trúc pipeline	4
4.1	Trích xuất và tiền xử lý âm thanh	4
4.2	Voice Activity Detection	4
4.3	Nhận dạng tiếng nói	4
4.4	Phân đoạn và căn chỉnh theo thời gian	4
4.5	Làm sạch và bổ sung ngữ cảnh	5
5	Định dạng dữ liệu đầu ra	5
6	Kế hoạch thực nghiệm và đánh giá	5
6.1	Dữ liệu	5

6.2	Chỉ số đánh giá	6
7	Kế hoạch triển khai	6
8	Rủi ro và phương án xử lý	6
9	Sản phẩm bàn giao và tiêu chí hoàn thành	7
10	Kết luận	7

1 Bối cảnh và vấn đề

Trong hệ thống phân tích video đa phương thức, dữ liệu hình ảnh và âm thanh thường được xử lý bởi các mô-đun độc lập. Mô-đun thị giác xác định ranh giới cảnh, keyframe, nội dung OCR và các đối tượng xuất hiện; trong khi mô-đun âm thanh tạo ra lời thoại cùng mốc thời gian. Nếu hai luồng dữ liệu không được căn chỉnh chính xác, nội dung lời thoại có thể bị gán nhầm cảnh, làm giảm chất lượng của các bước tóm tắt, truy hồi và suy luận phía sau.

Vì vậy, tập trung giải quyết hai bài toán chính:

1. Nhận dạng tiếng nói trong video với độ chính xác và tốc độ phù hợp;
2. Hạn chế hiện tượng *temporal drift*, tức sai lệch giữa mốc thời gian của lời thoại và ranh giới cảnh hình ảnh.

2 Mục tiêu và phạm vi

2.1 Mục tiêu

- Xây dựng pipeline tự động trích xuất và chuẩn hóa âm thanh từ video.
- Chuyển lời nói tiếng Việt thành văn bản có mốc thời gian ở mức câu, đoạn và, khi cần, mức từ.
- Ánh xạ các đoạn văn bản vào danh sách scene boundary do mô-đun thị giác cung cấp.
- Làm sạch và bổ sung ngữ cảnh cho văn bản nhưng không làm thay đổi nội dung gốc.
- Chuẩn hóa đầu ra JSON để tích hợp thuận lợi với các mô-đun còn lại.

2.2 Phạm vi

Phiên bản đầu ưu tiên video có lời thoại, một hoặc một số ít người nói, và ranh giới cảnh đã được mô-đun thị giác xác định. Nhận diện danh tính người nói, dịch đa ngôn ngữ và đồng bộ khẩu hình không thuộc phạm vi bắt buộc, nhưng có thể được mở rộng sau khi pipeline cơ sở đạt yêu cầu.


3 Lựa chọn mô hình

Ba phương án ASR được cân nhắc dựa trên độ chính xác, tốc độ, chi phí và khả năng kiểm soát dữ liệu. Các con số WER dưới đây là giá trị tham khảo từ nguồn benchmark mà nhóm đang sử dụng và cần được tái kiểm chứng trên cùng một tập kiểm thử trước khi đưa ra kết luận chính thức.

Phương án đề xuất: sử dụng Faster-Whisper (large-v3) làm mô hình mặc định. Lựa chọn này cân bằng giữa độ chính xác, tốc độ, chi phí vận hành và khả năng kiểm soát dữ liệu trong quá trình huấn luyện/thử nghiệm. Hai API còn lại được dùng làm baseline hoặc phương án dự phòng nếu ngân sách cho phép.

Bảng 1: So sánh các phương án nhận dạng tiếng nói

Mô hình	Vai trò	Ưu điểm	Hạn chế
Faster-Whisper large-v3	Giải pháp chính, chạy local	Tốc độ suy luận cao; hỗ trợ tiếng Việt tốt; chủ động dữ liệu và chi phí	Cần GPU và tối ưu bộ nhớ cho xử lý quy mô lớn
ElevenLabs Scribe v2	API thay thế	WER tiếng Việt tham khảo khoảng 1,9%; triển khai nhanh	Có chi phí API; dữ liệu được gửi tới bên thứ ba
Qwen3-ASR	API/mô hình thay thế	WER tiếng Việt tham khảo khoảng 2,4%; phù hợp luồng cần độ ổn định cao	Phụ thuộc dịch vụ, phiên bản và chính sách triển khai



Hình 1: Luồng xử lý tổng quát của mô-đun

4 Kiến trúc pipeline

4.1 Trích xuất và tiền xử lý âm thanh

Luồng âm thanh được tách khỏi video và chuyển về định dạng thống nhất, chẳng hạn mono PCM với tần số lấy mẫu 16 kHz. Âm lượng được chuẩn hóa về mức mục tiêu -16 LUFS để giảm khác biệt giữa các nguồn video. Các bước khử nhiễu chỉ được áp dụng khi cần thiết nhằm tránh làm mất đặc trưng lời nói.

4.2 Voice Activity Detection

VAD xác định các khoảng có tiếng nói và loại bỏ silence hoặc nhiễu nền kéo dài trước khi đưa dữ liệu vào ASR. Bước này giúp giảm thời gian suy luận, hạn chế văn bản ảo và tạo các đơn vị đầu vào hợp lý hơn. Một khoảng đệm ngắn được giữ ở hai đầu mỗi đoạn để tránh cắt mất âm tiết.

4.3 Nhận dạng tiếng nói

Faster-Whisper tạo ra văn bản cùng `start_time` và `end_time`. Chế độ word-level timestamp được bật cho các video cần căn chỉnh chi tiết. Pipeline lưu cả transcript thô và độ tin cậy để có thể truy vết hoặc hiệu chỉnh ở các bước sau.

4.4 Phân đoạn và căn chỉnh theo thời gian

Giả sử cảnh thứ i có khoảng thời gian $S_i = [s_i, e_i]$ và đoạn lời thoại thứ j có khoảng $A_j = [a_j, b_j]$. Độ giao nhau được tính bởi

$$I_{ij} = \max(0, \min(e_i, b_j) - \max(s_i, a_j)). \quad (1)$$

Đoạn lời thoại được gán cho cảnh có tỷ lệ chồng lấn lớn nhất:

$$R_{ij} = \frac{I_{ij}}{b_j - a_j + \varepsilon}, \quad i^* = \arg \max_i R_{ij}, \quad (2)$$

trong đó ϵ là hằng số nhỏ để tránh chia cho 0. Nếu một đoạn trải qua nhiều cảnh và tỷ lệ chồng lấn đều đáng kể, đoạn đó được tách tại scene boundary gần nhất bằng word-level timestamp. Các đoạn có mức chồng lấn thấp được đánh dấu để hậu kiểm thay vì gán cường bức.

4.5 Làm sạch và bổ sung ngữ cảnh

Sau khi chunking, một mô hình ngôn ngữ nhẹ có thể sửa dấu câu, lỗi viết hoa và nối các mảnh câu bị chia tại ranh giới cảnh. Mô hình chỉ được phép chuẩn hóa cách trình bày, không được thêm thông tin mới. Phiên bản đầu có thể sử dụng một mô hình nhanh thuộc lớp Flash; tên model cụ thể sẽ được cấu hình để dễ thay thế khi dịch vụ thay đổi. Transcript thô luôn được giữ lại bên cạnh bản đã làm sạch.

5 Định dạng dữ liệu đầu ra

Mỗi cảnh được đóng gói thành một đối tượng thống nhất giữa dữ liệu âm thanh và hình ảnh. Schema đề xuất như sau:

Listing 1: Cấu trúc JSON cho một cảnh

```
{
  "scene_id": 1,
  "time_range": {
    "start": 0.0,
    "end": 5.0
  },
  "audio_metadata": {
    "raw_text": "Noi dung nhan dang ban dau.",
    "clean_text": "Noi dung da duoc chuan hoa.",
    "summary": "Tom tat ngan cua loi thoai.",
    "language": "vi",
    "confidence": 0.94
  },
  "visual_metadata": {
    "keyframe_path": "frames/scene_001.jpg",
    "ocr_content": ["Van ban trong khung hinh"],
    "objects": ["person", "screen"]
  },
  "alignment_metadata": {
    "overlap_ratio": 0.91,
    "needs_review": false
  }
}
```

Việc bổ sung `clean_text`, `confidence` và `alignment_metadata` giúp hệ thống phân biệt dữ liệu gốc với dữ liệu đã xử lý, đồng thời hỗ trợ lọc các trường hợp cần kiểm tra thủ công.

6 Kế hoạch thực nghiệm và đánh giá

6.1 Dữ liệu

Pipeline được kiểm thử trước trên phần tiếng Việt của FLEURS để đo năng lực ASR trong điều kiện chuẩn. Sau đó, một tập con đại diện từ dữ liệu thực tế của cuộc thi được gán nhãn thủ công

về transcript và scene alignment. Tập này cần bao phủ các trường hợp giọng vùng miền, nhạc nền, nhiều người nói, tốc độ nói nhanh và chuyển cảnh dày.

6.2 Chỉ số đánh giá

- **WER/CER:** đo sai số từ và ký tự của transcript tiếng Việt.
- **Timestamp MAE:** sai số tuyệt đối trung bình của mốc bắt đầu và kết thúc so với nhãn chuẩn.
- **Scene Assignment Accuracy:** tỷ lệ đoạn thoại được gán đúng cảnh.
- **Real-Time Factor (RTF):** thời gian xử lý chia cho thời lượng video.
- **Tỷ lệ cần hậu kiểm:** phần trăm scene bị đánh dấu `needs_review`.

Thực nghiệm ablation sẽ lần lượt loại bỏ VAD, chuẩn hóa LUFs và contextual enrichment để xác định đóng góp thực tế của từng thành phần. Các model/API phải được đánh giá trên cùng dữ liệu, cùng quy tắc chuẩn hóa transcript và cùng phần cứng hoặc điều kiện dịch vụ tương đương.

7 Kế hoạch triển khai

Bảng 2: Tiến độ dự kiến trong bốn tuần

Giai đoạn	Công việc chính	Kết quả
Tuần 1	Trích xuất audio, chuẩn hóa LUFs, tích hợp VAD	Module tiền xử lý và bộ test cơ bản
Tuần 2	Tích hợp Faster-Whisper, xuất timestamp	Transcript có mốc thời gian và báo cáo WER/CER ban đầu
Tuần 3	Tích hợp scene boundary, xây dựng thuật toán alignment	JSON theo từng cảnh và các chỉ số cần chỉnh
Tuần 4	Làm sạch văn bản, benchmark và tối ưu	Pipeline hoàn chỉnh, tài liệu API và báo cáo đánh giá

8 Rủi ro và phương án xử lý

- **Nhiều, nhạc nền hoặc giọng chồng lấn:** điều chỉnh VAD, bổ sung khử nhiễu có kiểm soát và đánh dấu đoạn có confidence thấp.
- **Sai lệch scene boundary:** dùng ngưỡng chồng lấn mềm, word-level timestamp và cho phép một đoạn liên kết với hai cảnh liền kề.
- **LLM làm thay đổi nội dung:** giới hạn prompt, giữ transcript thô và kiểm tra độ tương đồng trước/sau khi làm sạch.
- **Thiếu tài nguyên GPU:** sử dụng quantization, batch inference hoặc chuyển sang model nhỏ hơn trong chế độ phát triển.
- **Sai khác giữa benchmark và dữ liệu thực tế:** ưu tiên kết quả trên tập validation nội bộ và cập nhật ngưỡng theo từng miền dữ liệu.

Nếu độ lệch đa phương thức vẫn lớn sau các bước trên, nhóm sẽ khảo sát Temporal Match Kernels hoặc phương pháp học tương quan giữa embedding hình ảnh và âm thanh như một hướng mở rộng, thay vì đưa ngay vào phiên bản tối thiểu.

9 Sản phẩm bàn giao và tiêu chí hoàn thành

- Mã nguồn pipeline có thể chạy lặp lại từ video đầu vào tới JSON đầu ra.
- Tập cấu hình cho model, VAD, ngưỡng alignment và thiết bị suy luận.
- Schema JSON và tài liệu giao tiếp với mô-đun thị giác.
- Bộ kiểm thử mẫu cùng báo cáo WER/CER, timestamp MAE, độ chính xác gắn cảnh và RTF.
- Danh sách trường hợp lỗi và cơ chế đánh dấu dữ liệu cần hậu kiểm.

Pipeline được xem là hoàn thành khi xử lý end-to-end ổn định trên tập validation, đầu ra tuân thủ schema đã thống nhất, các trường hợp confidence thấp được phát hiện rõ ràng và kết quả benchmark có thể tái lập trong cùng môi trường.

10 Kết luận

Đề xuất lựa chọn Faster-Whisper (large-v3) làm nền tảng nhận dạng tiếng nói và xây dựng lớp căn chỉnh dựa trên giao thời gian giữa transcript và scene boundary. Thiết kế ưu tiên khả năng chạy local, tính minh bạch của dữ liệu và khả năng thay thế từng thành phần. Việc kết hợp VAD, timestamp chi tiết, contextual enrichment có kiểm soát và metadata đánh giá chất lượng sẽ tạo ra nguồn dữ liệu đa phương thức nhất quán cho các tác vụ phía sau.